评阅人	得分

南 京 传 媒 学 院

《传媒数据管理与分析》

结 课 报 告

基于机器学习的网络新闻热度预测系统的设计与实现

学　　院：

专　　业：

班　　级：

姓　　名：_____

学　　号：_____

指导教师：

指导日期：　2026 年 10 月 29 日

南京传媒学院

2026 年 10 月 30 日

1. 引言

1.1 背景简介

网络新闻数量增长，传播效果受标题、内容和多媒体信息等多种因素影响。本项目使用历史新闻特征建立二分类模型，估计新闻分享量是否达到 1400 次，并提供网页操作界面。数据来自 UCI Online News Popularity，许可为 CC BY 4.0：https://archive.ics.uci.edu/dataset/332/online+news+popularity。

1.2 业务场景

使用者登录后输入新闻统计特征，选择决策树或随机森林获得预测，并可查看数据分析图和历史记录。模型使用历史英文新闻的统计特征，并不直接读取文章，也不保证实际传播效果。

1.3 开发环境

1.3.1 硬件配置要求

采用本机 Windows 计算机运行，模型训练及预测使用 CPU，内存与磁盘需满足 JDK、Python、Docker 及数据文件运行要求。

1.3.2 软件配置要求

Windows 11；JDK 21；独立 Conda 环境 news_popularity；MySQL 8.4 与 Redis 7.4 使用 Docker 容器；浏览器访问本机服务。

1.3.3 开发工具

使用 IntelliJ IDEA、Maven、Git、Docker Desktop 和浏览器；Spring Boot 内嵌 Tomcat。

1.3.4 主要的开发库和依赖项

后端使用 Spring Boot 3.5.6、Spring MVC、Spring Security、MyBatis、MySQL Connector 和 Spring Data Redis；前端使用 Vue 2.7 与 Element UI，前端资源随项目打包；Python 使用 pandas、scikit-learn、matplotlib、seaborn 和 joblib。Vue 2 已停止常规维护，本系统限定为本机课程演示。

1.3.5 Git 使用

项目已提交至公开仓库 https://github.com/AndyAlcott/news-popularity-final-coursework。以隔离的 git 练习.txt 建立 codex/git-practice 分支，在主分支和练习分支修改同一行后合并产生冲突，保留两处内容并完成合并提交；随后从远程仓库克隆并执行拉取验证。

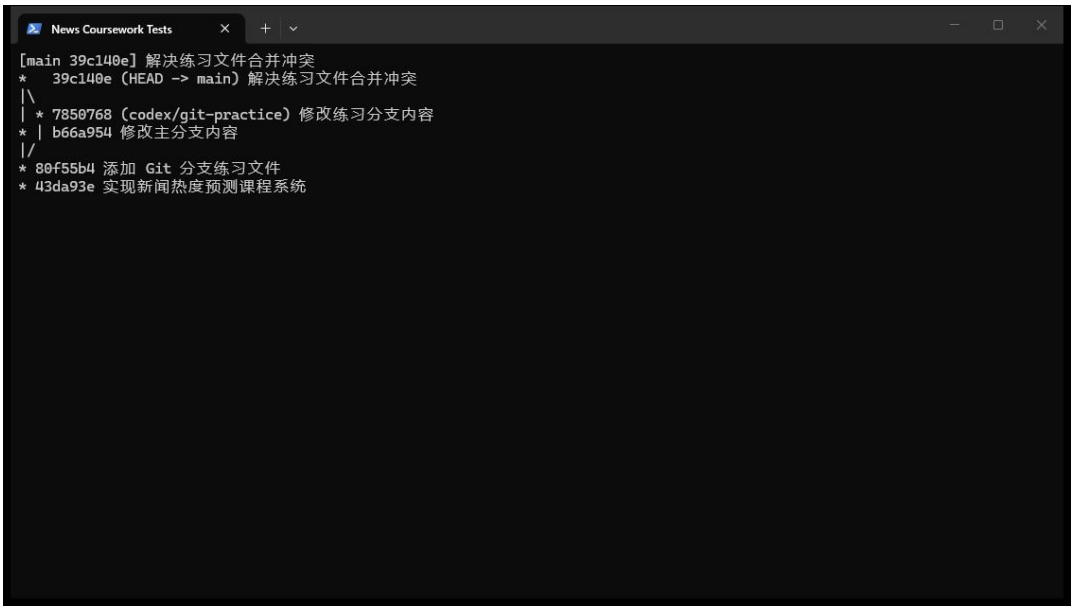


图 1 Git 冲突解决

2. 需求分析

2.1 系统功能需求

系统需要提供登录与退出、十项特征输入、模型选择、新闻热度预测、图表切换、预测记录查询和删除。未登录不能访问业务接口；输入无效时提示用户。账号由本机环境变量配置，不写入公开仓库。

2.2 用例分析

使用者登录后可输入特征、切换模型并预测，或查看分析图表、查询和删除记录；结束操作后可退出。系统主要用例如图所示。

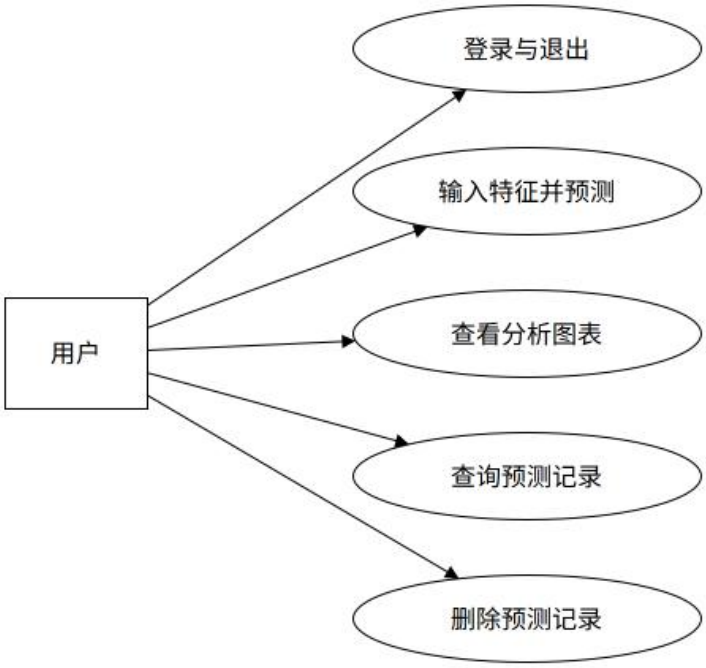


图 2 系统用例图

3. 概要设计

3.1 系统总体架构

浏览器加载本地 Vue 和 Element UI 资源，经 Spring MVC 接收请求，Spring Security 维护会话；MyBatis 访问 MySQL，评估结果读取后缓存于 Redis；Java 通过标准输入调用 Python 脚本，复用期中训练模型。

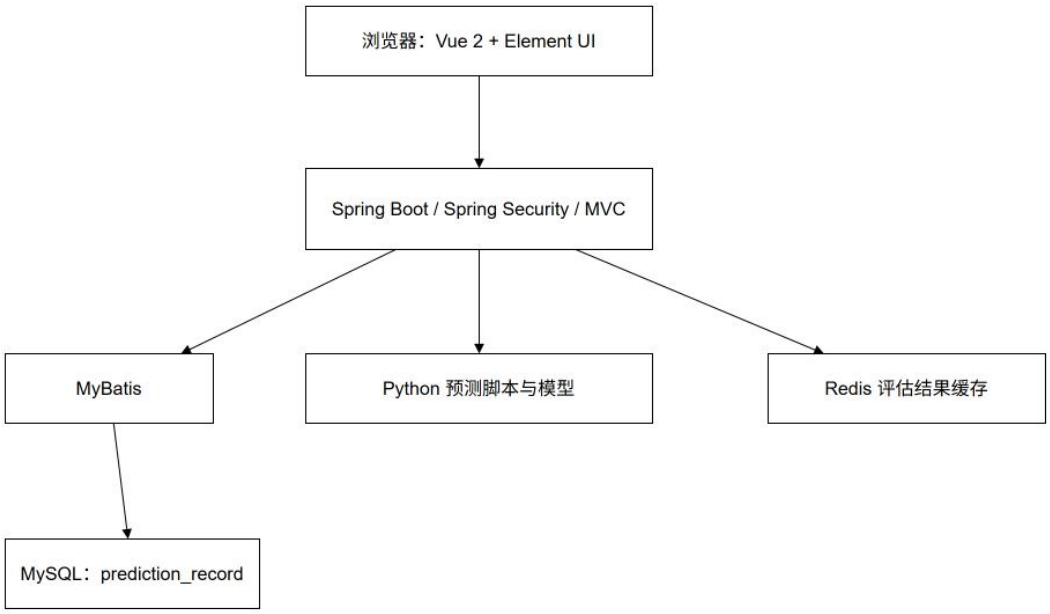


图 3 系统总体架构图

3.2 各模块设计

3.2.1 数据库设计

数据库实际只有 prediction_record 预测记录实体，保存模型、输入特征、类别、概率和时间。登录账号来自本机配置，不设置用户表或虚构实体关系。

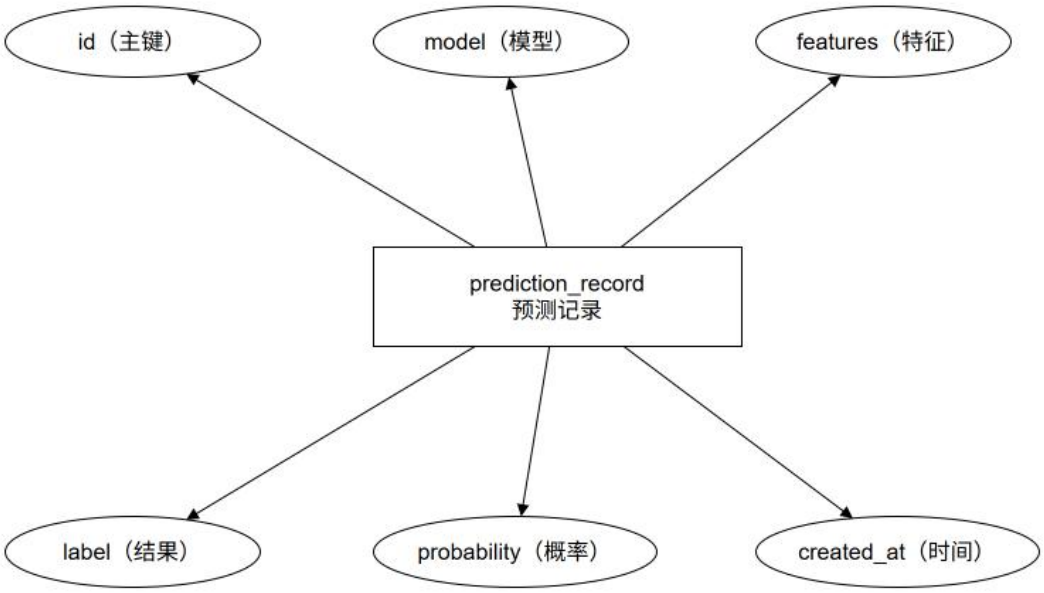


图 4 预测记录实体 E-R 图

3.2.2 算法模型设计

决策树和随机森林分别保存完整的填补、标准化和分类流程；输入特征顺序由 features.json 统一规定，分享次数仅用于生成标签，不作为预测输入。

3.2.3 前端设计

前端使用 Vue 2.7 和 Element UI，以左侧导航切换预测、数据分析和预测记录。登录表单单独显示；静态资源由 Spring Boot 本地提供。

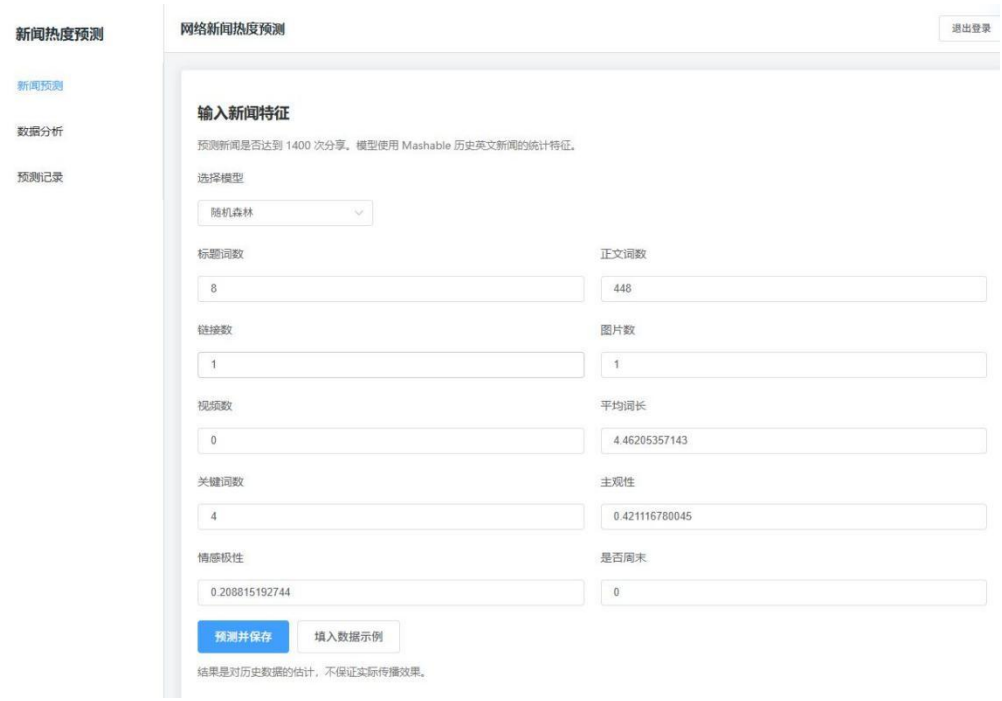


图 5 新闻预测界面

3.2.4 后端设计

Spring Security 对会话及 CSRF 进行验证；控制器读取模型指标和图表，调用 Python 预测并经 MyBatis 保存记录。Redis 缓存评估结果 10 分钟，数据库持久化预测记录。

4. 详细设计

4.1 数据库详细设计

预测记录表结构如表 4.1 所示。

表 4.1 预测记录表（prediction_record）

序号	字段名称	字段类型	字段约束	字段描述
1	id	BIGINT	PRIMARY KEY	记录编号
2	model	VARCHAR(30)	NOT NULL	模型名称

序号	字段名称	字段类型	字段约束	字段描述
3	features	TEXT	NOT NULL	输入特征 JSON
4	label	VARCHAR(20)	NOT NULL	预测类别
5	probability	DOUBLE	NOT NULL	热度概率
6	created_at	TIMESTAMP	NOT NULL	创建时间

4.2 算法模型详细设计

4.2.1 算法模型选择

决策树通过特征阈值递归划分数据，结构直观；随机森林组合多棵树的预测，以降低单棵树对数据扰动的敏感性。两者均以是否达到 1400 次分享为分类目标。

4.2.2 模型训练流程

读取 39644 条数据，选取标题词数、正文词数、链接数、图片数、视频数、平均词长、关键词数、主观性、情感极性和是否周末共十项特征。固定随机种子 42，按 8:2 分层划分训练与测试集；在训练集内部进行交叉验证和参数搜索，测试集只用于最终评估。缺失值填补与标准化纳入流水线，避免测试集信息泄漏。

4.3 前端详细设计

登录成功后页面显示导航和输入表单；点击“预测并保存”后显示类别与热度概率。图表页面支持切换图表，记录页面可查询与删除。图为输入示例的预测结果。

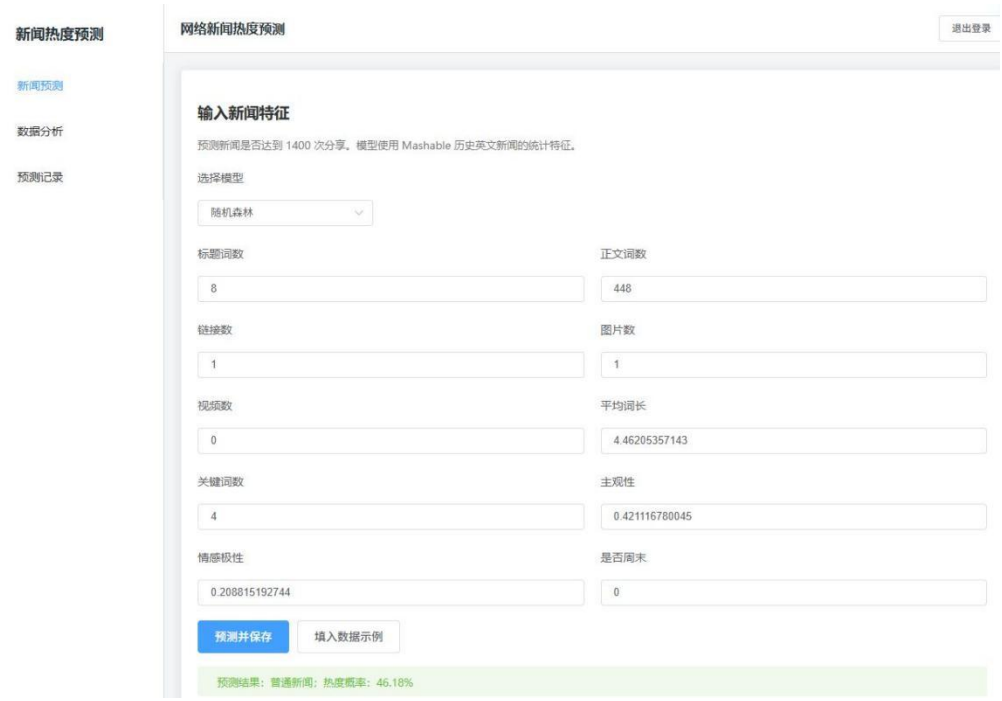


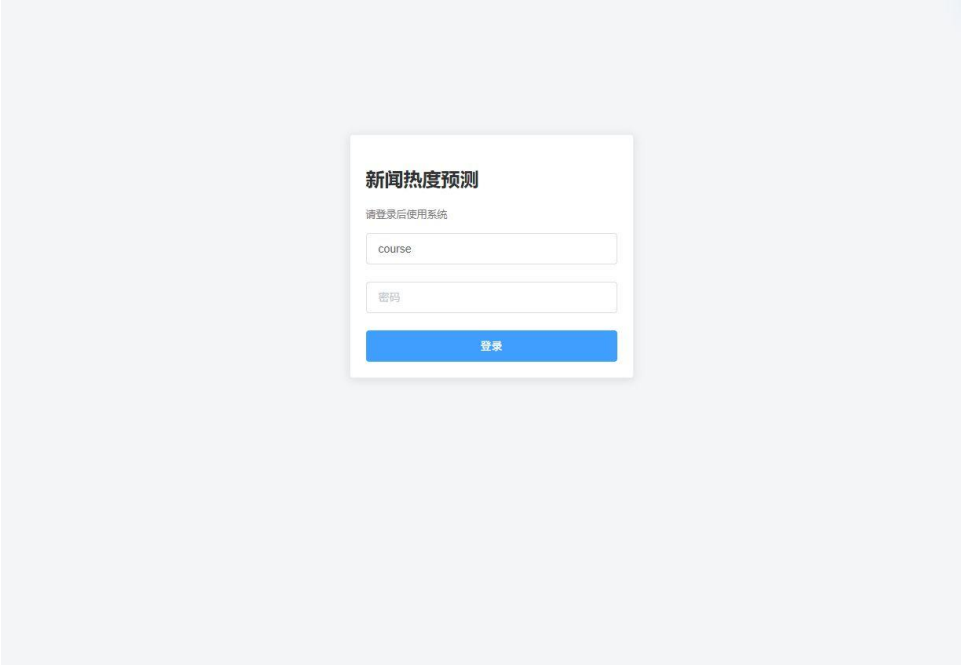
图 6 示例预测结果

4.4 后端详细设计

前端先取得 CSRF 令牌并提交登录请求；会话建立后访问 /api/schema、/api/metrics、/api/figure、/api/predict 和 /api/records。预测 JSON 通过标准输入交给 Python，返回结果后写入 MySQL。请求字段经 Python 校验，服务异常时返回提示。

5. 系统测试

5.1 前端测试



图：系统登录界面

验证登录页面、导航、特征输入、模型选择、预测显示、图表和记录页面。示例新闻由随机森林预测为普通新闻，概率为 46.18%；该结果仅针对当前示例。

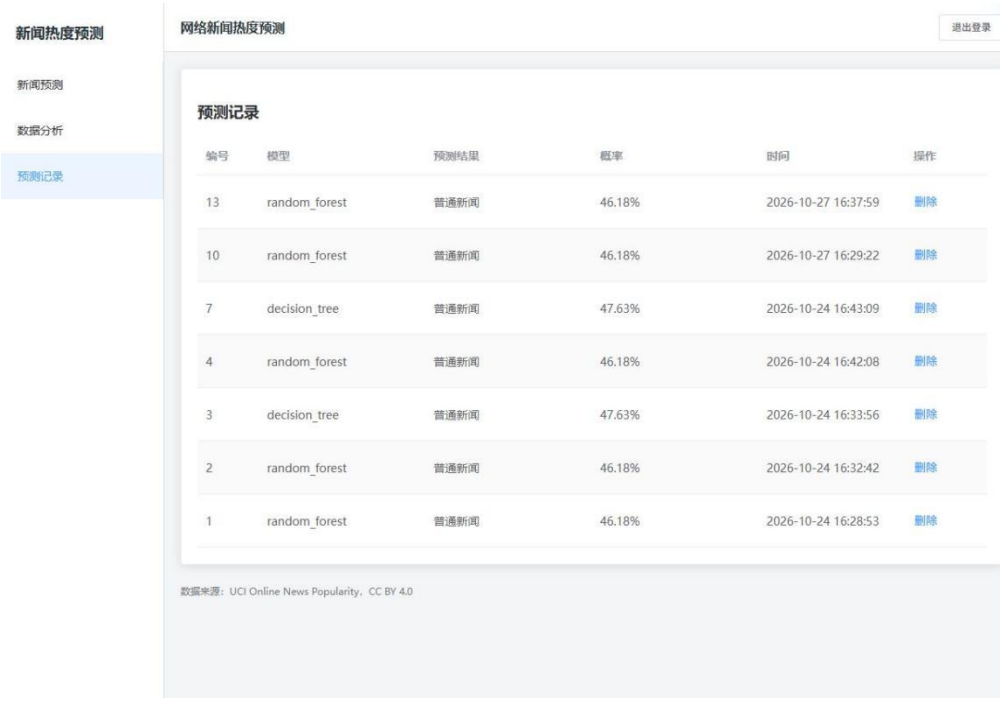


图 7 预测记录页面

5.2 后端测试

使用独立测试程序检查未登录访问、错误密码、正确登录、CSRF、Redis 缓存、两种模型的 Python 与网页结果一致性、记录查询和删除、非法输入及退出；本次列出的检查均通过。

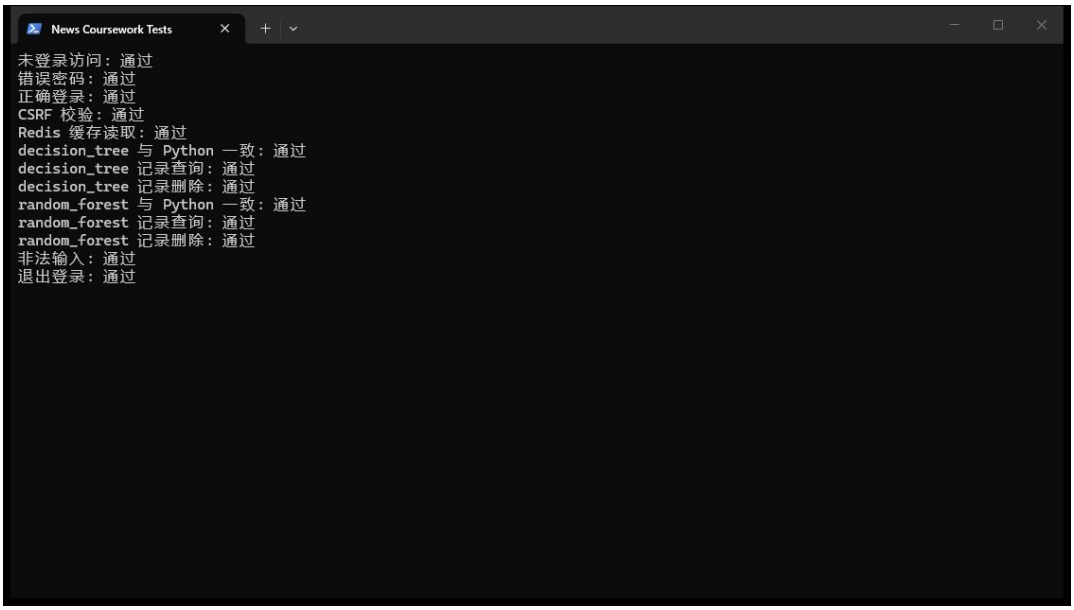


图 8 接口测试结果

测试环境信息如下表所示。

测试环境表

操作系统	Windows 11
数据库	MySQL 8.4
应用软件	网络新闻热度预测系统
浏览器	Google Chrome

运行环境	JDK 21、Python Conda 环境

测试用例：

预测功能测试用例表

用例编号	TEST01
用例名称	新闻热度预测
所属模块	新闻预测
测试数据	数据集示例，随机森林
步骤描述	1. 登录，填入示例特征，点击预测并保存
预期结果	显示类别与概率，并新增一条记录
实际结果	显示普通新闻，概率 46.18%，记录可查询

6. 性能分析及评估

6.1 模型选择依据

决策树便于解释特征分裂，适合作为简单基线。随机森林通过多棵决策树集成处理特征之间的非线性关系，适用于新闻热度这种受多种因素共同影响的分类问题。

6.2 实验设置与评估指标

训练集 31715 条，测试集 7929 条。按测试集计算准确率、精确率、召回率和 F1；调参使用训练集交叉验证。结果基于所选十项特征和本次划分，不能视为对所有新闻的预测保证。

6.3 结果对比与分析

决策树：准确率 58.52%，精确率 59.84%，召回率 67.71%，F1 为 63.53%；随机森林：准确率 60.95%，精确率 61.99%，召回率 69.35%，F1 为 65.46%。随机森林在本次测试中四项指标均较高，但总体预测能力有限，需要结合实际场景谨慎使用。

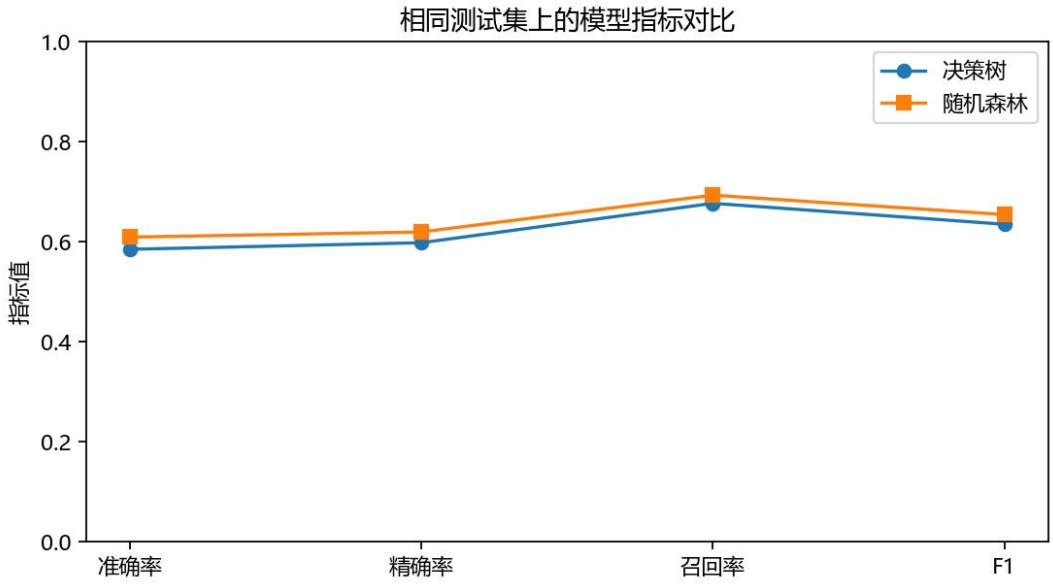


图 9 模型评估指标对比

图中随机森林四项指标均较高，结果不代表其他数据集。

7. 结论与展望

7.1 主要结论

系统完成两个模型的训练结果复用，网页能够登录、预测、查看图表和管理记录。测试中随机森林优于决策树，系统实现了 Python 算法与 Java Web 的基本集成。

7.2 不足与展望

数据为历史英文新闻，不能直接代表其他平台、语言或当前新闻；输入中的情感等指标需要按数据集一致方式计算。后续可引入更多合法数据、开展时间外验证，并评估模型在新场景下的稳定性。

8. 对课程的认识与收获

通过本项目，练习了数据清洗、模型训练与评估，理解了训练集与测试集隔离的重要性，也实践了 Maven、Git 分支合并、Spring Boot 接口、MyBatis 数据持久化和前后端联调。